

Universidade da Beira Interior

Departamento de Informática



**Departamento de
Informática**

Elementos de Inteligência Artificial e Ciência de Dados

Análise de Dados Aplicada ao Acompanhamento Nutricional

Elaborado por:

Leandro Apolo N: 55459
Jorge Altamirano N: 55456
Jose Gordon N: 55432

Docentes:

Professor João C. Neves
Professor Tiago Filipe Dias dos Santos Roxo

28 de maio de 2026

Agradecimentos

A conclusão deste trabalho não seria possível sem o apoio de várias pessoas a quem o grupo deixa o seu sincero agradecimento.

Agradecemos aos docentes da unidade curricular de Elementos de Inteligência Artificial e Ciência de Dados (EIACD) pela orientação, pelo enunciado bem estruturado e pela disponibilidade demonstrada ao longo do semestre.

Agradecemos também aos colegas pela troca de ideias durante o desenvolvimento, e à Universidade da Beira Interior (UBI) pelas condições proporcionadas para a realização deste projeto.

Conteúdo

1	Introdução	1
1.1	Enquadramento	1
1.2	Motivação	1
1.3	Objetivos	1
1.4	Organização do Documento	2
2	Integração de Dados	3
2.1	Os Quatro Ficheiros de Origem	3
2.2	Estratégia de Junção	3
2.3	Resultado da Integração	4
3	Limpeza e Processamento de Dados	5
3.1	Visão Geral	5
3.2	Normalização das Colunas de Texto	5
3.3	Remoção de Colunas Redundantes	5
3.4	Tratamento de Valores em Falta	5
3.5	Tratamento de Outliers	6
3.6	Resultado Final	6
4	Análise Exploratória de Dados	7
4.1	Visão Geral	7
4.2	Análise de Correlações	7
4.3	Resultados por Tipo de Dieta	8
4.4	Resultados por Sexo	8
4.5	Influência do Perfil do Nutricionista	9
4.6	Síntese da Análise	9
5	Identificação de Padrões e Modelos de Previsão	11
5.1	Identificação de Padrões por Clustering	11
5.1.1	Método Utilizado	11
5.1.2	Perfis Encontrados	11
5.1.3	O Grupo Anómalo e a Qualidade dos Dados	12
5.2	Modelo de Regressão	12
5.2.1	Seleção de Variáveis e Prevenção de Data Leakage	12
5.2.2	Divisão dos Dados e Treino	13
5.3	Modelo de Classificação	13
5.3.1	Definição da Variável de Sucesso	13
5.3.2	Treino e Resultados	13

6	Discussão Crítica e Conclusões	15
6.1	Comparação dos Modelos	15
6.2	Interpretação dos Resultados	15
6.3	Limitações do Trabalho	16
6.4	Trabalho Futuro	16
6.5	Conclusão	16

Lista de Figuras

4.1	Mapa de calor das correlações de Pearson entre as variáveis numéricas.	8
4.2	Variação de peso aos seis meses por tipo de dieta.	9
4.3	Variação de peso aos seis meses por sexo do paciente.	10
4.4	Perda média de peso por abordagem do nutricionista.	10
5.1	Grupos de pacientes segundo o peso inicial e a variação de peso.	12

Lista de Tabelas

2.1	Dimensão dos ficheiros de origem e do conjunto integrado.	3
3.1	Valores em falta no conjunto integrado e estratégia adotada.	6
4.1	As cinco variáveis mais correlacionadas com a variação de peso aos seis meses. . .	7
5.1	Perfil médio de cada grupo identificado por <i>clustering</i>	11
5.2	Desempenho dos modelos de regressão no conjunto de validação.	13
5.3	Desempenho dos modelos de classificação no conjunto de validação.	14

Acrónimos

EIACD Elementos de Inteligência Artificial e Ciência de Dados

CSV *Comma-Separated Values*

IMC Índice de Massa Corporal

UBI Universidade da Beira Interior

Capítulo 1

Introdução

1.1 Enquadramento

A prevalência de doenças crónicas associadas a hábitos alimentares inadequados, como a obesidade, a diabetes tipo 2 e as doenças cardiovasculares, tem aumentado a atenção dada à nutrição como fator de saúde. Neste contexto, o acompanhamento nutricional personalizado tornou-se uma ferramenta relevante na promoção de estilos de vida mais saudáveis e na melhoria dos indicadores clínicos dos pacientes.

A eficácia de uma dieta não depende apenas do plano alimentar em si. Depende também de fatores biológicos do paciente, do seu comportamento e nível de adesão, e até do perfil do profissional que faz o acompanhamento. Esta combinação de fatores torna difícil prever, à partida, que planos têm maior probabilidade de sucesso para um determinado perfil de paciente.

1.2 Motivação

O interesse deste problema está em perceber se os dados recolhidos durante o acompanhamento nutricional contêm informação suficiente para antecipar resultados. Se for possível estimar com alguma fiabilidade quanto peso um paciente vai perder, ou se uma dieta tem boa probabilidade de sucesso, então essa informação pode apoiar decisões clínicas antes de a dieta começar.

O grupo abordou o problema através de um conjunto de dados que reúne informação sobre pacientes, planos dietéticos, nutricionistas responsáveis e resultados das dietas ao fim de seis meses. O objetivo foi explorar e caracterizar esses dados, identificar padrões associados ao sucesso ou insucesso das dietas, e construir modelos capazes de fazer previsões úteis.

1.3 Objetivos

O trabalho consistiu na construção de um conjunto de *scripts* em Python que executam, de forma encadeada, todas as etapas de um processo de análise de dados. As etapas vão desde a integração dos quatro ficheiros *Comma-Separated Values* (CSV) fornecidos até à aplicação de modelos de previsão e à discussão crítica dos resultados obtidos.

Em concreto, os objetivos foram integrar os dados num único conjunto, limpar e transformar esse conjunto, realizar uma análise exploratória detalhada, identificar grupos de pacientes através de *clustering*, treinar modelos supervisionados para prever quer a perda de peso quer o sucesso da dieta, e por fim comparar e discutir o desempenho desses modelos.

1.4 Organização do Documento

O documento está organizado em seis capítulos. Depois desta introdução, o segundo capítulo descreve a integração dos dados e a estrutura do conjunto unificado. O terceiro apresenta a limpeza e o processamento aplicados. O quarto descreve a análise exploratória e os padrões diretos encontrados. O quinto trata da identificação de padrões por *clustering* e da aplicação dos modelos de previsão. O último capítulo apresenta a discussão crítica dos resultados e as conclusões do trabalho.

Capítulo 2

Integração de Dados

2.1 Os Quatro Ficheiros de Origem

Os dados foram fornecidos em quatro ficheiros CSV distintos, cada um correspondente a uma parte do problema. O ficheiro `patients.csv` contém os registos dos pacientes, com 1000 linhas e atributos como sexo, idade, altura, peso inicial, Índice de Massa Corporal (IMC), hábito tabágico, horas de sono e um indicador de motivação. O ficheiro `nutritionists.csv` descreve os 20 nutricionistas, com a sua abordagem de acompanhamento, anos de experiência e especialidade. O ficheiro `diets.csv` caracteriza os 10 planos alimentares, indicando o tipo de dieta e a sua composição em macronutrientes. Por fim, o ficheiro `outcomes.csv` regista 2523 programas de dieta, cada um ligando um paciente, um nutricionista e uma dieta a um resultado medido ao fim de seis meses.

A relação entre os ficheiros faz-se através de identificadores. Cada programa em `outcomes.csv` refere um `patient_id`, um `nutritionist_id` e um `diet_id`, que funcionam como chaves para os outros três ficheiros.

2.2 Estratégia de Junção

A integração foi implementada no `script data_integration.py`, recorrendo à biblioteca *pandas* [3]. O grupo optou por usar o ficheiro `outcomes.csv` como tabela central, uma vez que é o que tem mais linhas e o que representa a unidade de análise do problema, ou seja, um programa de dieta com o seu resultado.

A partir dessa tabela central foram feitas três junções do tipo *left join*. A primeira liga cada programa aos dados do respetivo paciente pela coluna `patient_id`. A segunda junta as características da dieta pela coluna `diet_id`. A terceira acrescenta a informação do nutricionista pela coluna `nutritionist_id`. A escolha do *left join* garante que nenhum programa é perdido durante a integração, mesmo que algum identificador não tenha correspondência nos ficheiros secundários.

Ficheiro	Linhas	Colunas
<code>patients.csv</code>	1000	11
<code>nutritionists.csv</code>	20	5
<code>diets.csv</code>	10	9
<code>outcomes.csv</code>	2523	9
<code>merged_data.csv</code>	2523	31

Tabela 2.1: Dimensão dos ficheiros de origem e do conjunto integrado.

2.3 Resultado da Integração

O conjunto integrado, guardado em `merged_data.csv`, ficou com 2523 linhas e 31 colunas, como mostra a tabela 2.1. O número de linhas mantém-se igual ao de `outcomes.csv`, o que confirma que a junção não duplicou nem eliminou programas. O *script* imprime na consola as dimensões dos quatro ficheiros originais e a dimensão do conjunto final, precisamente para permitir esta verificação. Cada linha passou a conter, num só local, toda a informação necessária para analisar um programa de dieta: o perfil do paciente, as características da dieta seguida, o perfil do nutricionista e o resultado obtido.

Já nesta fase ficou visível que o conjunto integrado tinha problemas de qualidade. Várias colunas apresentavam valores em falta, algumas colunas pareciam repetidas e os campos de texto tinham representações inconsistentes. O tratamento destes problemas é descrito no capítulo seguinte.

Capítulo 3

Limpeza e Processamento de Dados

3.1 Visão Geral

A limpeza e o processamento foram concentrados no *script* `data_cleaning.py`, que recebe o conjunto integrado e produz o ficheiro `cleaned_data.csv`. Durante o desenvolvimento, o grupo criou também dois *scripts* auxiliares, `fix_sex_column.py` e `fix_text_columns.py`, à medida que foram sendo detetados problemas nas colunas de texto. Numa fase posterior, a lógica destes dois *scripts* foi integrada diretamente no *script* principal de limpeza, de modo a que todo o processamento ficasse num único passo.

3.2 Normalização das Colunas de Texto

A coluna `sex` foi a que apresentou pior estado. O mesmo conceito aparecia escrito de várias formas diferentes, incluindo `F`, `f`, `F`, `female`, `M`, `m`, `M` e `male`. Sem tratamento, os passos seguintes tratariam cada variante como uma categoria distinta. Este problema só ficou totalmente visível na fase de análise exploratória, quando o resumo por sexo apresentou oito grupos em vez de dois. A solução adotada converte a coluna para texto, remove espaços, passa tudo a maiúsculas e substitui `FEMALE` por `F` e `MALE` por `M`, ficando apenas dois valores válidos.

As restantes colunas de texto, `diet_name`, `diet_type`, `approach` e `specialty`, tinham um problema semelhante, com espaços a mais e diferenças de maiúsculas. A solução aplica a estas colunas a remoção de espaços e uma normalização de formato em que a primeira letra fica maiúscula e as restantes minúsculas.

3.3 Remoção de Colunas Redundantes

A inspeção do conjunto integrado revelou colunas que não acrescentavam informação. A coluna `bmi_redundant` era uma cópia de `baseline_bmi`. A coluna `experience_years` era idêntica a `years_experience`. Estas duas colunas foram eliminadas para evitar redundância e o risco de introduzir correlações artificiais na análise. Com esta remoção, o conjunto passou de 31 para 29 colunas.

3.4 Tratamento de Valores em Falta

Várias colunas tinham valores em falta, conforme se resume na tabela 3.1. O grupo aplicou estratégias diferentes consoante o tipo de coluna.

As linhas sem valor nas variáveis-chave `weight_change_kg_6m` e `adherence_ratio` foram removidas. A razão é que estas variáveis representam o resultado da dieta, e preencher valores em falta no resultado introduziria informação artificial que enviesaria toda a análise. Esta remoção

Coluna	Valores em falta	Estratégia
<code>approach</code>	289	Moda
<code>fiber_target_g</code>	254	Mediana
<code>sodium_limit_mg</code>	252	Mediana
<code>years_experience</code>	245	Mediana
<code>sleep_hours</code>	200	Mediana
<code>mean_adherence_pct</code>	150	Remoção da linha
<code>adherence_ratio</code>	150	Remoção da linha
<code>age</code>	143	Mediana
<code>motivation_score</code>	129	Mediana
<code>weight_change_kg_6m</code>	151	Remoção da linha

Tabela 3.1: Valores em falta no conjunto integrado e estratégia adotada.

eliminou 290 linhas. Para as restantes colunas numéricas, os valores em falta foram preenchidos com a mediana. As colunas categóricas foram preenchidas com a moda.

3.5 Tratamento de Outliers

Para o tratamento de *outliers* foi aplicado o método do intervalo interquartil às variáveis `age`, `baseline_weight_kg`, `height_cm` e `weight_change_kg_6m`. Este método define como limites aceitáveis o primeiro e o terceiro quartil alargados por uma vez e meia o intervalo interquartil. Em vez de eliminar as linhas fora destes limites, o grupo optou por uma estratégia de *capping*, ou seja, os valores extremos foram limitados ao valor da fronteira mais próxima. A vantagem desta abordagem é não perder linhas, aproveitando a restante informação do registo, mesmo quando uma das suas variáveis apresentava um valor anómalo.

A inclusão de `weight_change_kg_6m` neste tratamento foi uma melhoria introduzida numa fase posterior do trabalho, depois de o grupo ter observado, no gráfico de *clustering*, dois registos com variações de peso próximas de mais e menos cem quilogramas. Estes valores eram claramente erros e ficavam fora do tratamento original, que se aplicava apenas a três variáveis.

3.6 Resultado Final

Depois de todas as operações, o conjunto limpo guardado em `cleaned_data.csv` ficou com 2233 linhas e 29 colunas, sem qualquer valor em falta. A validação final do *script* confirma que a coluna `sex` passou a ter apenas os valores F e M, e que a coluna `approach` ficou com quatro categorias bem definidas. Este conjunto serviu de base a todas as análises descritas nos capítulos seguintes.

Capítulo 4

Análise Exploratória de Dados

4.1 Visão Geral

A análise exploratória foi feita no *script* `eda_analysis.py`, que produz um conjunto de gráficos e estatísticas a partir do ficheiro `cleaned_data.csv`. O objetivo desta fase foi compreender a distribuição das variáveis, identificar relações diretas entre elas e perceber quais os fatores aparentemente mais ligados ao resultado das dietas. Os gráficos gerados são guardados numa pasta própria e foram usados como base para a análise apresentada neste capítulo.

4.2 Análise de Correlações

O grupo calculou a matriz de correlação de Pearson entre todas as variáveis numéricas e identificou as cinco variáveis mais correlacionadas com a variação de peso aos seis meses, a variável central do problema. A tabela 4.1 apresenta esses resultados.

Variável	Correlação com a variação de peso
<code>adherence_ratio</code>	-0,63
<code>mean_adherence_pct</code>	-0,63
<code>motivation_score_program</code>	-0,51
<code>baseline_weight_kg</code>	-0,43
<code>motivation_score</code>	-0,32

Tabela 4.1: As cinco variáveis mais correlacionadas com a variação de peso aos seis meses.

A leitura destes valores é direta. A adesão ao plano é a variável mais correlacionada com a perda de peso. Como a perda de peso é registada como valor negativo, uma correlação negativa de -0,63 significa que quanto maior a adesão, maior a perda. A motivação do paciente segue a mesma lógica. O peso inicial também está associado a maior perda, o que é esperado, já que pacientes mais pesados tendem a perder mais em termos absolutos.

A matriz revelou ainda um facto importante. As variáveis `adherence_ratio` e `mean_adherence_pct` apresentam exatamente a mesma correlação com o resultado, o que indica que medem essencialmente a mesma coisa. Esta redundância foi tida em conta na fase de modelação.

A figura 4.1 apresenta o mapa de calor da matriz de correlação completa, gerado pelo *script*. As zonas mais escuras, vermelhas ou azuis, identificam os pares de variáveis mais correlacionados, e permitem confirmar visualmente as relações descritas.

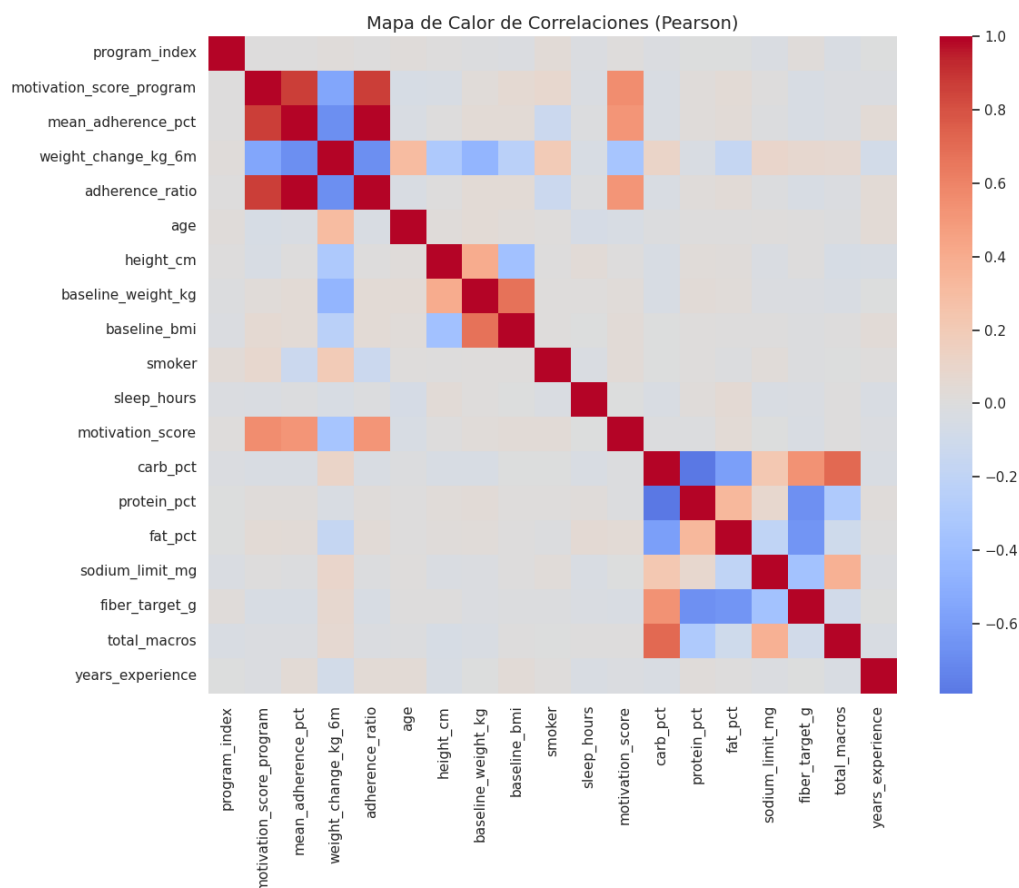


Figura 4.1: Mapa de calor das correlações de Pearson entre as variáveis numéricas.

4.3 Resultados por Tipo de Dieta

A análise da perda média de peso por tipo de dieta mostrou diferenças, embora moderadas. As dietas de baixo teor de hidratos de carbono, agrupadas em **Low_carb**, apresentam a maior perda média, próxima de 24 kg. Seguem-se as dietas de base vegetal e as ricas em proteína, e por fim as equilibradas, com perda média de cerca de 21 kg. A diferença entre o melhor e o pior tipo de dieta é de aproximadamente 3 kg em média, o que sugere que o tipo de dieta tem influência, mas não é o fator dominante. A figura 4.2 mostra a distribuição da variação de peso para cada tipo de dieta.

4.4 Resultados por Sexo

A comparação por sexo revelou uma diferença assinalável. Os pacientes do sexo masculino apresentam uma perda média de cerca de 24,9 kg, enquanto as pacientes do sexo feminino apresentam uma perda média de cerca de 19,3 kg. A diferença média entre os dois grupos é de aproximadamente 5,6 kg.

Esta diferença é relevante, mas deve ser interpretada com cuidado. Parte dela pode dever-se a fatores fisiológicos, já que a perda de peso depende da composição corporal, mas pode também refletir diferenças noutras variáveis distribuídas de forma desigual entre os dois grupos. A figura 4.3 apresenta a distribuição da variação de peso para cada sexo.

Importa ainda referir que foi precisamente esta análise por sexo que tornou visível o problema de inconsistência na coluna **sex**, descrito no capítulo anterior. Numa execução inicial, o resumo apresentou oito grupos em vez de dois, o que levou o grupo a reforçar a normalização desta




Figura 4.2: Variação de peso aos seis meses por tipo de dieta.

coluna.

4.5 Influência do Perfil do Nutricionista

O grupo analisou o efeito da abordagem do nutricionista no resultado das dietas. Os resultados mostram que a abordagem mais exigente, identificada como **Strict**, está associada à maior perda média de peso, cerca de 23,8 kg. As abordagens **Motivational** e **Empathetic** situam-se em valores intermédios, e a abordagem **Data_driven** apresenta a menor perda média, cerca de 20,4 kg. Já a especialidade do nutricionista mostrou pouca influência, com perdas médias muito próximas entre as quatro especialidades, todas entre 21,7 e 22,1 kg. A figura 4.4 apresenta a perda média de peso para cada abordagem.

4.6 Síntese da Análise

Desta fase ficaram duas conclusões principais. A primeira é que o comportamento do paciente, traduzido na adesão e na motivação, é de longe o fator mais ligado ao resultado, mais do que qualquer característica da dieta ou do nutricionista. A segunda é que existem variáveis redundantes no conjunto, nomeadamente o par formado pela adesão e pelo rácio de adesão, que devem ser tratadas com cuidado na modelação.




Figura 4.3: Variação de peso aos seis meses por sexo do paciente.




Figura 4.4: Perda média de peso por abordagem do nutricionista.

Capítulo 5

Identificação de Padrões e Modelos de Previsão

5.1 Identificação de Padrões por Clustering

A análise exploratória do capítulo anterior revelou relações diretas entre pares de variáveis. Para procurar padrões mais complexos, que envolvam várias variáveis ao mesmo tempo, o grupo recorreu a aprendizagem não supervisionada. Esta parte foi implementada no *script clustering.py*.

5.1.1 Método Utilizado

O algoritmo escolhido foi o *K-Means* [1], por ser simples de interpretar e adequado a variáveis numéricas. Foram usadas como entrada cinco características relevantes para descrever o perfil dos pacientes e o seu resultado: idade, peso inicial, motivação, adesão média e variação de peso aos seis meses.

Antes da aplicação do algoritmo, todas as variáveis foram padronizadas com o *StandardScaler*. Este passo é necessário porque o *K-Means* se baseia em distâncias, e sem padronização as variáveis de maior escala, como o peso, dominariam o cálculo face a variáveis de menor escala, como a motivação. O número de grupos foi fixado em quatro, com o objetivo de identificar quatro perfis distintos de pacientes.

5.1.2 Perfis Encontrados

A tabela 5.1 resume os quatro grupos identificados.

Grupo	Pacientes	Idade	Motivação	Adesão	Perda de peso
0	646	44,7	0,55	60,0%	−14,1 kg
1	857	31,9	0,79	85,9%	−27,9 kg
2	5	42,0	5,00	79,2%	−23,8 kg
3	725	56,9	0,78	85,3%	−21,8 kg

Tabela 5.1: Perfil médio de cada grupo identificado por *clustering*.

A leitura dos três grupos principais conta uma história clara. O grupo 1 reúne os pacientes mais jovens, com idade média de 32 anos, alta adesão e a maior perda de peso. O grupo 3 reúne pacientes mais velhos, com idade média de 57 anos, com a mesma motivação e adesão dos mais jovens, mas com menor perda de peso. Esta diferença entre os grupos 1 e 3, com comportamento semelhante mas resultados diferentes, é coerente com o efeito da idade no metabolismo. O grupo

0 reúne os pacientes com motivação e adesão mais baixas, e é, como seria de esperar, o que perde menos peso.

A figura 5.1 mostra a distribuição dos pacientes segundo o peso inicial e a variação de peso, com cada grupo representado por uma cor.




Figura 5.1: Grupos de pacientes segundo o peso inicial e a variação de peso.

5.1.3 O Grupo Anómalo e a Qualidade dos Dados

O grupo 2 merece destaque próprio. Contém apenas cinco registos e distingue-se por um valor de motivação de exatamente 5,0, enquanto todos os outros pacientes apresentam valores entre 0,15 e 0,99. Este valor não corresponde a pacientes extraordinariamente motivados, mas a um erro na introdução dos dados. Estes registos foram provavelmente preenchidos numa escala de 1 a 5, em vez da escala de 0 a 1 usada no resto do conjunto.

O facto de o *K-Means* ter isolado automaticamente estes cinco registos num grupo próprio é, em si, um resultado relevante. Mostra que as técnicas de *clustering*, para além de identificarem perfis de pacientes, funcionam também como uma ferramenta de deteção de problemas de qualidade dos dados que tinham passado despercebidos nas fases anteriores.

5.2 Modelo de Regressão

A primeira abordagem ao problema de previsão consistiu em estimar a quantidade de peso perdida pelo paciente ao fim de seis meses. Esta tarefa foi implementada no *script* `predictive_modeling.py` com recurso à biblioteca *scikit-learn* [2].

5.2.1 Seleção de Variáveis e Prevenção de Data Leakage

A seleção das variáveis preditoras foi a decisão mais importante desta fase. Em primeiro lugar, foram removidas as colunas de identificação, como os identificadores de paciente, dieta e nutricionista, por não terem qualquer valor preditivo.

Em segundo lugar, e mais importante, foram removidas as variáveis que só são conhecidas durante ou depois do programa de dieta, nomeadamente a adesão média, o rácio de adesão, a motivação registada durante o programa e o índice do programa. A razão para esta remoção é

evitar um problema conhecido como *data leakage*. Se o modelo usasse a adesão para prever a perda de peso, estaria a usar informação que, na prática, ainda não existe no momento em que a previsão é útil, isto é, antes de a dieta começar. Um modelo treinado com essa informação teria um desempenho aparentemente excelente, mas seria inútil numa situação real. Ao remover estas variáveis, o grupo garantiu que o modelo só usa informação disponível à partida.

5.2.2 Divisão dos Dados e Treino

Seguindo a indicação do enunciado, os dados foram divididos em quatro partes: 50% para treino, 30% para validação, 10% para teste e 10% reservados e não utilizados. Esta última parte foi deliberadamente posta de lado para reduzir o risco de *overfitting* indireto. Na prática, isto traduziu-se em 1116 linhas para treino, 669 para validação e 224 para teste.

Foram treinados três modelos de regressão de naturezas diferentes: uma regressão linear, uma *random forest* e um *gradient boosting*. A tabela 5.2 apresenta os resultados no conjunto de validação.

Modelo	MSE	RMSE (kg)	R^2
Regressão linear	23,32	4,83	0,582
<i>Random forest</i>	12,56	3,54	0,775
<i>Gradient boosting</i>	9,83	3,13	0,824

Tabela 5.2: Desempenho dos modelos de regressão no conjunto de validação.

O *gradient boosting* foi o modelo com melhor desempenho. Aplicado ao conjunto de teste, manteve a qualidade, com um R^2 de 0,806 e um erro médio de 3,23 kg. Este resultado significa que o modelo consegue prever a perda de peso de um paciente, antes de a dieta começar, com um erro típico próximo de três quilogramas.

5.3 Modelo de Classificação

Para complementar a regressão, o grupo abordou também o problema como classificação, no *script classification_model.py*. O objetivo é responder de forma direta à pergunta: dado o perfil de um paciente, esta dieta vai ou não ter sucesso?

5.3.1 Definição da Variável de Sucesso

Como o conjunto de dados não inclui uma variável binária de sucesso, foi necessário construí-la. Foi definida como sucesso a perda de mais de 28% do peso inicial ao fim de seis meses. Este limiar foi escolhido por produzir uma divisão equilibrada das classes, com cerca de 55% de casos de sucesso e 45% de insucesso, o que evita problemas de classes desproporcionadas que dificultariam o treino.

5.3.2 Treino e Resultados

A preparação das variáveis preditoras seguiu exatamente a mesma lógica do modelo de regressão, com a mesma remoção de identificadores e das variáveis afetadas por *data leakage*. A divisão dos dados foi também a mesma de 50/30/10/10, desta vez com estratificação pela classe de sucesso para garantir a mesma proporção de casos positivos em todos os conjuntos.

Foram treinados três classificadores: uma árvore de decisão, uma regressão logística e uma *random forest*. O enunciado pedia preferência por modelos interpretáveis, e a árvore de decisão respeita diretamente essa indicação. A tabela 5.3 mostra o desempenho no conjunto de validação.

A *random forest* obteve o melhor desempenho. Aplicada ao conjunto de teste, atingiu uma *accuracy* de 0,853 e um *F1 score* de 0,870. Em termos práticos, este resultado significa que o

Modelo	Accuracy	F1 Score
Árvore de decisão	0,803	0,828
Regressão logística	0,815	0,839
<i>Random forest</i>	0,824	0,848

Tabela 5.3: Desempenho dos modelos de classificação no conjunto de validação.

modelo acerta em cerca de 85% dos casos quando classifica uma dieta como bem-sucedida ou mal-sucedida, usando apenas informação conhecida no momento da primeira consulta.

Capítulo 6

Discussão Crítica e Conclusões

6.1 Comparação dos Modelos

O trabalho aplicou dois tipos de modelos supervisionados ao mesmo problema, com objetivos diferentes. Os modelos de regressão estimam quantos quilogramas perde o paciente, e os modelos de classificação respondem se a dieta é ou não bem-sucedida. A combinação dos dois oferece uma visão mais completa do problema do que qualquer das abordagens isoladamente.

Entre os modelos de regressão, a diferença entre a regressão linear e os modelos baseados em árvores foi clara. A regressão linear obteve o pior desempenho, com um coeficiente de determinação de 0,582. A *random forest* e o *gradient boosting* ficaram bastante acima, com valores de 0,775 e 0,824 respectivamente. A razão para o desempenho mais fraco da regressão linear está na sua própria natureza. Este modelo assume que a relação entre as variáveis e o resultado é linear, ou seja, que cada variável contribui de forma fixa e independente das outras. A perda de peso, porém, é um processo biológico complexo, em que fatores como a idade, o peso inicial e o tipo de dieta interagem entre si de formas não lineares.

Os modelos baseados em árvores não têm essa limitação. Ao dividirem os dados sucessivamente segundo as várias variáveis, conseguem representar interações e relações não lineares de forma natural. O *gradient boosting*, em particular, combina muitas árvores corrigindo os erros das anteriores, o que explica o seu melhor desempenho. Foi o modelo de regressão escolhido como melhor neste estudo.

Na classificação, os três modelos testados apresentaram desempenhos próximos, todos acima de 80% de *accuracy*. A *random forest* obteve o melhor resultado, mas a árvore de decisão simples ficou muito perto, com apenas dois pontos percentuais de diferença. Este facto é relevante porque o enunciado pedia preferência por modelos interpretáveis, e uma árvore de decisão única é muito mais interpretável que uma floresta. Em contexto real, a perda de desempenho seria provavelmente compensada pelo ganho de interpretabilidade.

6.2 Interpretação dos Resultados

A conclusão mais sólida de todo o trabalho é que o resultado de uma dieta depende sobretudo do comportamento do paciente. A adesão ao plano e a motivação foram, em todas as fases da análise, os fatores mais ligados à perda de peso. Em termos práticos, isto sugere que, para um profissional de saúde, garantir que o paciente segue o plano é mais determinante do que a escolha entre uma dieta e outra.

O tipo de dieta tem influência, mas pequena. A diferença de perda média entre o melhor e o pior tipo de dieta foi de cerca de 3 kg. O perfil do nutricionista mostrou um efeito moderado, com a abordagem mais exigente associada a melhores resultados, enquanto a especialidade se mostrou praticamente irrelevante.

Os modelos finais respondem às duas perguntas práticas que o enunciado sugeria. À pergunta sobre quanto peso vai perder um paciente, o modelo de regressão responde com um erro típico próximo de 3 kg. À pergunta sobre se uma dieta vai ter sucesso, o modelo de classificação responde com cerca de 85% de acerto. Ambos os modelos usam apenas informação conhecida antes do início da dieta, o que faz com que sejam, em princípio, aplicáveis em contexto clínico real.

6.3 Limitações do Trabalho

O grupo identificou várias limitações que condicionam a leitura dos resultados. A primeira diz respeito à variável de resultado. No conjunto de dados, todos os programas registaram perda de peso, sem um único caso de ganho ou de manutenção. Um conjunto de dados realista de acompanhamento nutricional teria também casos de insucesso, e a sua ausência faz com que o problema de classificação não distinga propriamente sucesso de fracasso, mas sim graus de sucesso. A definição de sucesso adotada, com um limiar de perda de 28% do peso inicial, foi uma escolha do grupo motivada pelo equilíbrio das classes, e não um critério clínico.

A segunda limitação está nos dados do clustering. A análise revelou cinco registos com motivação fora de escala, que foram aproveitados como exemplo do potencial da técnica para detetar erros. No entanto, o facto de estes erros terem sobrevivido às fases anteriores de limpeza mostra que ainda podem existir outros problemas de qualidade não detetados, sobretudo em registos que não se afastam tanto da norma.

Por fim, importa referir que todas as conclusões deste trabalho assentam num único conjunto de dados. Uma validação dos modelos com dados de pacientes reais, recolhidos de forma independente, seria indispensável antes de qualquer aplicação prática.

6.4 Trabalho Futuro

A partir das limitações identificadas, o grupo aponta algumas direções de melhoria. A primeira seria trabalhar com um conjunto de dados que incluísse casos de insucesso reais, o que tornaria os modelos verdadeiramente capazes de distinguir bons e maus resultados. A segunda seria realizar uma análise mais aprofundada da importância das variáveis, com técnicas como *permutation importance* ou *SHAP values*, para perceber não só quais as variáveis mais influentes mas também como cada uma influencia individualmente as previsões. A terceira seria validar os modelos com um conjunto de dados externo, recolhido em contexto clínico real.

6.5 Conclusão

O trabalho percorreu todas as etapas de um processo de análise de dados, da integração dos quatro ficheiros até à aplicação e discussão de modelos de previsão. As principais conclusões são que o comportamento do paciente, sobretudo a adesão ao plano, é o fator mais determinante para o resultado de uma dieta, que é possível prever a perda de peso com um erro médio próximo de 3 kg, e que se pode classificar o sucesso de uma dieta com cerca de 85% de fiabilidade usando apenas informação inicial. O processo permitiu ainda detetar, através do *clustering*, problemas de qualidade nos dados que não eram visíveis de outra forma. A metodologia desenvolvida é aplicável a conjuntos de dados mais completos, e os resultados obtidos abrem caminho a futuras extensões em direção a uma utilização clínica efetiva.

Bibliografia

- [1] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media, 3rd edition, 2022.
- [2] Fabian Pedregosa et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [3] The Pandas Development Team. pandas: Python data analysis library. [Online] <https://pandas.pydata.org/>. Último acesso a 20 de Maio de 2026.